КБТУ · МАШИННОЕ ОБУЧЕНИЕ · ЛАБОРАТОРНАЯ РАБОТА 2

Прогнозирование удовлетворённости жизнью по ВВП на душу населения

Отчёт о лабораторной работе: линейная регрессия и регрессия методом k ближайших соседей в scikit-learn

1. Цель и задачи

Цель работы — предсказать, насколько жители страны удовлетворены жизнью, по одному признаку: ВВП на душу населения. Работа закрепляет три навыка из лекций:

- загрузка и визуализация реальных данных с помощью `pandas` и `matplotlib`;
- обучение и сравнение двух регрессионных моделей в scikit-learn: линейной регрессии и метода k ближайших соседей (KNN);
- интерпретация результатов моделей и обсуждение того, насколько хорошо они обобщаются на новые данные.

2. Данные

Файл `lifesat.csv` содержит 27 стран и три столбца: `Country` (страна), `GDP per capita (USD)` (ВВП на душу населения) и `Life satisfaction` (удовлетворённость жизнью по шкале от 0 до 10). Вывод `df.info()` показывает, что пропусков нет: во всех столбцах 27 непустых значений. Описательные статистики из `df.describe()`:

Статистика	ВВП на душу (USD)	Удовлетворённость
количество	27	27
среднее	41 565	6,57
станд. отклонение	9 631	0,77
минимум	26 456	5,40
25-й перцентиль	33 938	5,90
медиана	41 627	6,80
75-й перцентиль	49 691	7,30
максимум	60 236	7,60

ВВП всех стран лежит примерно в диапазоне от 26 000 до 60 000 USD, а удовлетворённость — от 5,4 до 7,6. Этот узкий диапазон важен для выводов: модели никогда не видели ни более бедных, ни более богатых стран.

3. Исследование данных

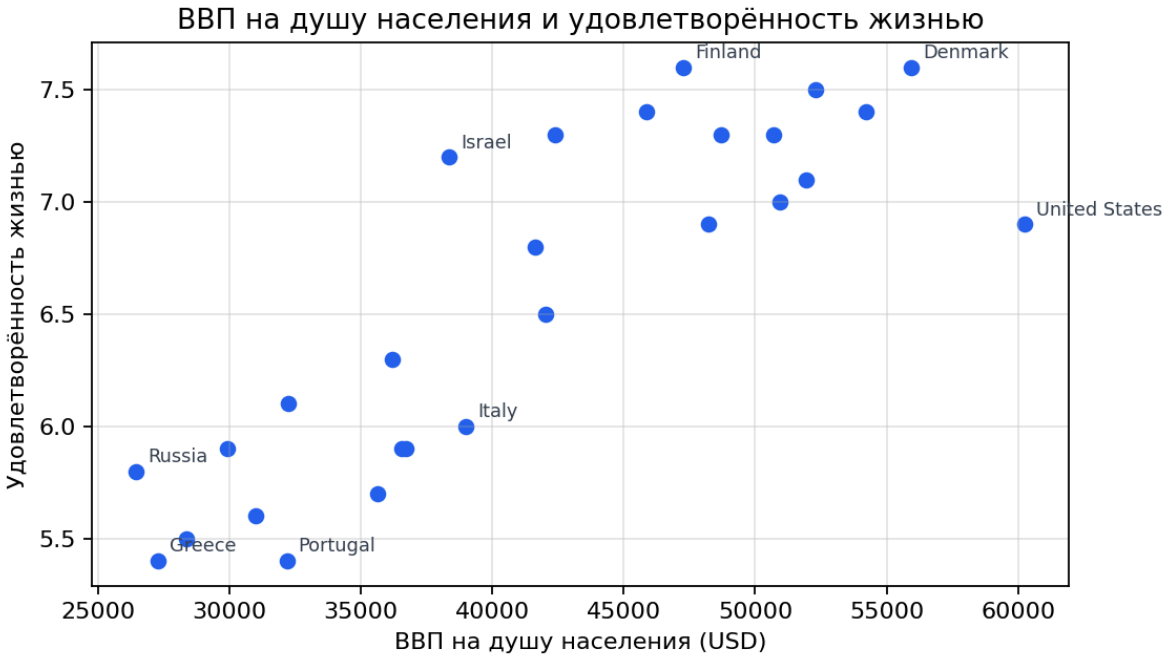


Рисунок 1. ВВП на душу населения и удовлетворённость жизнью (вопрос Q3).

Диаграмма рассеяния показывает **явную положительную, примерно линейную связь**: в более богатых странах удовлетворённость жизнью в среднем выше. Коэффициент корреляции Пирсона **r ≈ 0,85**, то есть связь сильная. При этом точки не лежат на одной прямой: Израиль при среднем ВВП показывает 7,2, а США, самая богатая страна выборки, — только 6,9. Значит, ВВП объясняет значительную часть различий, но важны и другие факторы, а сама по себе корреляция не доказывает, что деньги являются причиной счастья.

4. Линейная регрессия

4.1 Модель

Матрица признаков и целевая переменная получены как `X = df[["GDP per capita (USD)"]].values` и `y = df[["Life satisfaction"]].values`. Обе имеют форму **(27, 1)**. Двойные квадратные скобки сохраняют двумерность данных, потому что scikit-learn ожидает признаки в виде матрицы размера (число объектов, число признаков).

Линейная регрессия описывает целевую переменную прямой:

$$\hat{y} = \theta_0 + \theta_1 \cdot x$$

Параметры находятся методом наименьших квадратов, который минимизирует среднеквадратичную ошибку MSE = (1/m) Σ $(\hat{y}_i - y_i)^2$.

4.2 Результаты

Величина	Значение	Смысл
Коэффициент θ_1 (`coef_`)	6,779e-05	+1000 USD ВВП ≈ +0,068 балла удовлетворённости
Свободный член θ_0 (`intercept_`)	3,749	прогноз при ВВП = 0 (экстраполяция, практического смысла не имеет)
R^2 на обучающих данных	0,73	прямая объясняет ~73% разброса
RMSE / MAE на обучающих данных	0,39 / 0,31	типичная ошибка в баллах

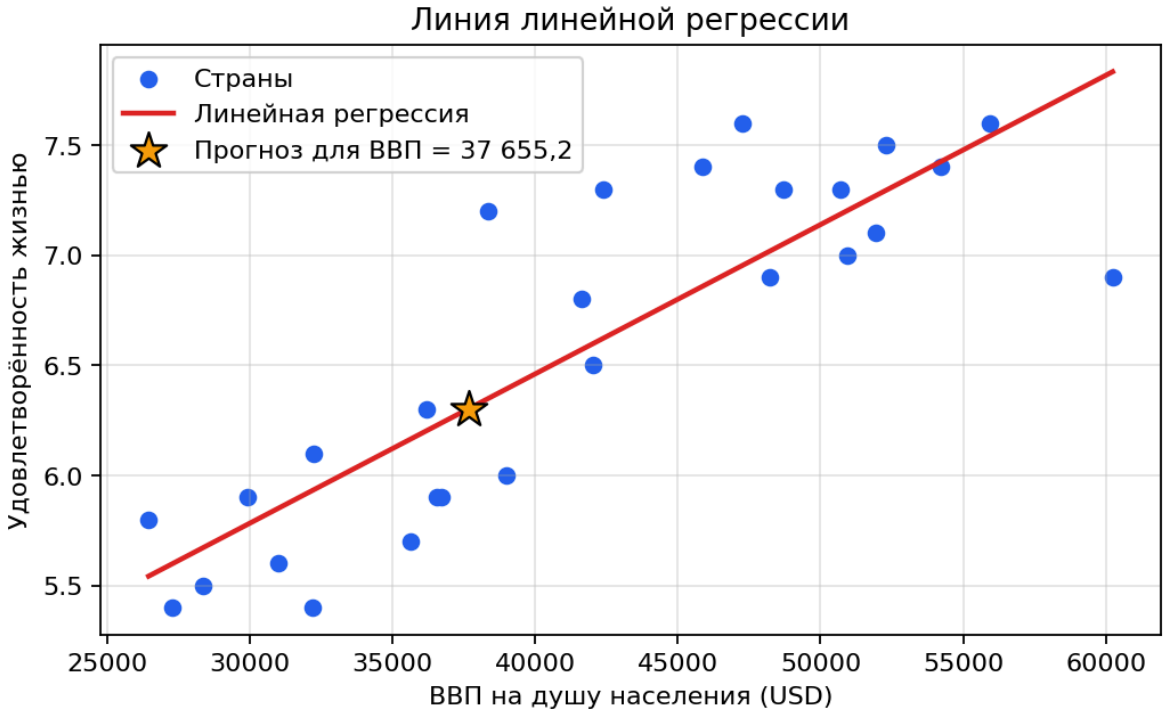


Рисунок 2. Линия регрессии на фоне данных (Q6) и прогноз для ВВП = 37 655,2 USD (Q7).

4.3 Прогноз для ВВП = 37 655,2 USD

$$\hat{y} = 3{,}749 + 6{,}779\text{e-}05 \times 37\,655{,}2 \approx \mathbf{6{,}30}$$

Прогноз удовлетворённости жизнью — около **6,30**. Значение правдоподобно: оно лежит между оценками стран с похожим ВВП (Литва и Словения 5,9, Италия 6,0, Испания 6,3, Израиль 7,2) и соответствует общему восходящему тренду.

5. Регрессия методом k ближайших соседей

5.1 Модель

KNN-регрессия не обучает параметры. Она запоминает обучающие данные, а для новой точки находит *k* ближайших к ней обучающих точек (по евклидову расстоянию) и возвращает **среднее** их целевых значений. Это обучение *на основе примеров* (instance-based), в отличие от линейной регрессии, которая является обучением *на основе модели* (model-based).

Пять стран, ближайших к ВВП = 37 655,2 USD:

#	Страна	ВВП (USD)	Расстояние	Удовлетворённость
1	Israel	38 341	686	7,2
2	Lithuania	36 732	923	5,9
3	Slovenia	36 548	1 107	5,9
4	Italy	38 992	1 337	6,0
5	Spain	36 215	1 440	6,3

При k = 3 прогноз равен (7,2 + 5,9 + 5,9) / 3 ≈ **6,33**. Он отличается от прогноза линейной регрессии (6,30) всего на 0,032: модели согласуются, потому что новая точка лежит внутри диапазона обучающих данных.

5.2 Влияние числа соседей

k	Прогноз для ВВП = 37 655,2	R^2 на обучающих данных
1	7,20	1,00
3	6,33	0,85
5	6,26	0,81
10	6,37	0,82

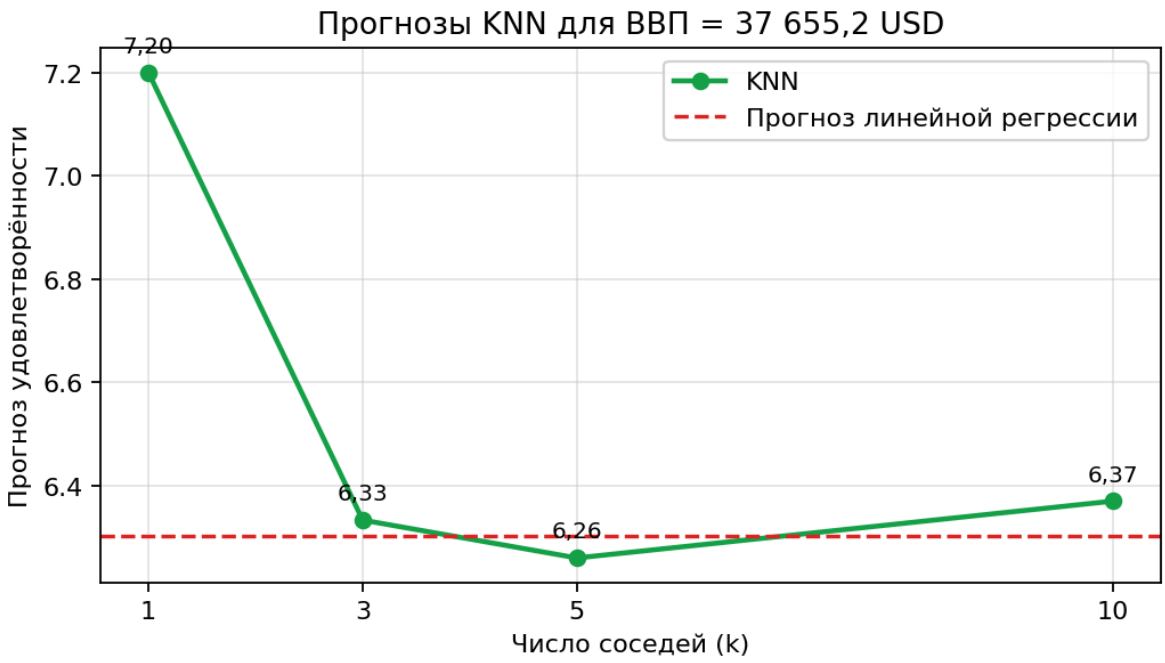


Рисунок 3. Прогнозы KNN при разных k (Q10).

- **k = 1** копирует значение одной ближайшей страны (Израиль, 7,2). Прогноз зависит от одной, возможно нетипичной точки, а на обучающих данных модель даёт идеальный результат (R^2 = 1,00), потому что каждая точка — сама себе ближайший сосед. Это признак **переобучения** (высокая дисперсия), а не хорошей модели.
- **k = 3, 5, 10** усредняют больше стран, поэтому прогнозы стабилизируются около 6,3–6,4, близко к результату линейной регрессии.
- Слишком большое k приводит к **недообучению** (высокое смещение): при k = 27 модель всегда предсказывает общее среднее 6,57.

6. Сравнение моделей и обобщающая способность

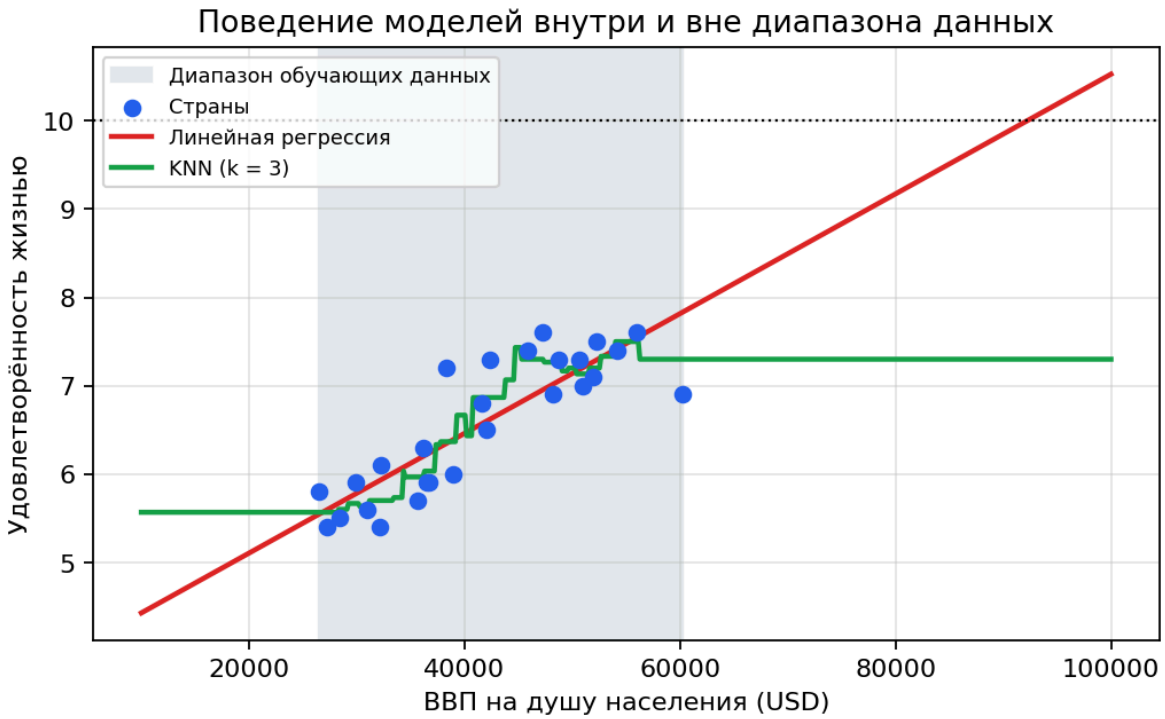


Рисунок 4. Линейная регрессия и KNN (k = 3) внутри и вне диапазона данных. Пунктир — максимально возможная оценка 10.

	Линейная регрессия	**KNN-регрессия**
Тип обучения	на основе модели: находит два параметра	на основе примеров: хранит все данные
Форма прогноза	прямая линия	ступенчатая кривая, повторяющая локальные данные
Прогноз при 37 655,2 USD	6,30	6,33 (k = 3)
Прогноз при 100 000 USD	10,53 (выше шкалы 0–10)	7,30 (упирается в самые богатые страны)
Главный гиперпараметр	нет	k — число соседей

Внутри диапазона данных обе модели дают похожие ответы. За его пределами они ошибаются по-разному: линейная регрессия растёт неограниченно и быстро начинает предсказывать невозможные значения, а KNN просто повторяет значения крайних стран. Ни одной модели нельзя доверять далеко от данных, на которых она обучалась.

Ограничения анализа

- **Нет разделения на обучающую и тестовую выборки.** Обе модели обучены и оценены на одних и тех же 27 точках, поэтому измерить их обобщающую способность нельзя. Нужна отложенная тестовая выборка или кросс-валидация.
- **Очень маленькая выборка.** При 27 наблюдениях результаты чувствительны к отдельным странам.

- **Смещённая выборка.** В данные вошли только страны с ВВП от 26 000 до 60 000 USD.
- **Один признак.** Удовлетворённость жизнью зависит также от здоровья, свободы, социальной поддержки и других факторов.
- **Масштабирование признаков.** При нескольких признаках KNN требует масштабирования (например, `StandardScaler`), так как основан на расстояниях.

7. Выводы

ВВП на душу населения сильно и положительно связан с удовлетворённостью жизнью ($r \approx 0{,}85$). Простая линейная регрессия объясняет около 73% разброса и для страны с ВВП 37 655,2 USD предсказывает 6,30. KNN-регрессия при $k = 3$ даёт очень близкое значение 6,33. Число соседей управляет балансом между переобучением (малое k) и недообучением (большое k). Поскольку выборка маленькая, охватывает узкий диапазон ВВП и не была разделена на обучающую и тестовую части, полученные результаты хорошо описывают наблюдаемые страны, но их нельзя переносить на очень бедные или очень богатые страны.

Приложение: основной код

```
import pandas as pd
import numpy as np
from sklearn.linear_model import LinearRegression
from sklearn.neighbors import KNeighborsRegressor

df = pd.read_csv("lifesat.csv")
X = df[["GDP per capita (USD)"]].values      # shape (27, 1)
y = df[["Life satisfaction"]].values         # shape (27, 1)

lin_reg = LinearRegression().fit(X, y)
print(lin_reg.coef_[0][0], lin_reg.intercept_[0])
print(lin_reg.predict([[37655.2]]))           # ~6.30

for k in [1, 3, 5, 10]:
    knn = KNeighborsRegressor(n_neighbors=k).fit(X, y)
    print(k, knn.predict([[37655.2]]))        # 7.20, 6.33, 6.26, 6.37
```